

NLP-Емо-01

Распознавание эмоций по тексту

Диаграммы, схемы и описание слайдов


Этот документ содержит:

- Диаграмму Use Case (варианты использования)
 - Диаграмму классов (Class Diagram)
 - Диаграмму объектов (Object Diagram)
 - Схему пайплайна обработки текста
 - Схему архитектуры проекта
- Подробное описание каждого слайда с готовым текстом

МГТУ им. Н.Э. Баумана, кафедра ИУ10, группа ИУ10-44
Осипова П.С., Селина М.А. | Преподаватель: Буркацкий К.А.

1. Диаграмма Use Case (варианты использования)

Показывает, что может делать пользователь с системой. Эту диаграмму можно вставить в отчёт и/или на отдельный слайд.




Описание вариантов использования

- **Ввести текст** — пользователь вводит произвольный текст на русском языке (до 1000 символов)
- **Получить эмоцию** — система возвращает метку эмоции (одну из 10) и уверенность в процентах
- **Вызвать /help** — система показывает справку: список эмоций, доступные команды
- **Вызвать /exit** — корректное завершение работы программы
- **Обучить модель** — запуск обучения (train.py или train_bert.py) перед первым использованием

2. Диаграмма классов (Class Diagram)

Показывает основные классы и модули проекта и связи между ними.



Описание модулей

- **data_loader** — загрузка данных из Hugging Face или локального CSV/JSON, разбиение 80/20
- **preprocessing** — предобработка текста: lowercase, пунктуация, стоп-слова, лемматизация
- **vectorizer** — TF-IDF векторизация, сохранение/загрузка обученного векторизатора
- **model** — классические ML-модели (LogReg, RandomForest), обёрнуты в OneVsRest
- **bert_model** — BERT-классификатор (EmotionClassifier), обучение, сохранение, инференс
- **evaluate** — расчёт метрик: Accuracy, Precision, Recall, F1, Confusion Matrix
- **cli** — консольный интерфейс: ввод текста, вывод эмоции, обработка команд и ошибок

3. Диаграмма объектов (Object Diagram)

Показывает конкретные объекты в момент работы программы — когда пользователь вводит текст и получает результат.





Диаграмма показывает конкретный пример: текст «Меня это бесит, я в ярости!» проходит через предобработку, векторизуется в разреженную матрицу размером (1, 10000), подаётся в модель OneVsRestClassifier, которая возвращает результат: «гнев», 92%.

4. Схема пайплайна обработки текста (детальная)


Подробная схема, показывающая оба пути обработки: через TF-IDF и через BERT.



Оба пути ведут к одному результату: метка эмоции + уверенность. TF-IDF — быстрый, но менее точный путь. BERT — медленнее, но понимает контекст и даёт лучшие результаты.

5. Схема архитектуры проекта (модули и файлы)

Показывает, какие файлы за что отвечают и как связаны.



Связи между модулями

- **main.py** → **cli.py** → **model.py** или **bert_model.py** (в зависимости от флага `--bert`)
- **train.py** → **data_loader** → **preprocessing** → **vectorizer** → **model** → **evaluate**
- **train_bert.py** → **data_loader** → **bert_model** → **evaluate**
- **cli.py** → **preprocessing** + **vectorizer** + **model** (TF-IDF) ИЛИ **bert_model** (BERT)

6. Подробное описание каждого слайда

Для каждого слайда: заголовок, содержание (можно копировать), какие картинки/диаграммы вставить, и что говорить при защите.

СЛАЙД 1: ТИТУЛЬНЫЙ

Заголовок: «Распознавание эмоций по тексту»

- Шифр проекта: NLP-Eмо-01
- МГТУ им. Н.Э. Баумана, кафедра ИУ10, группа ИУ10-44
- Исполнители: Осипова П.С., Селина М.А.
- Преподаватель: Буркацкий К.А.
- 2025/2026 учебный год

Подсказка: Стандартный титульный слайд. Никаких картинок.

СЛАЙД 2: ПОСТАНОВКА ЗАДАЧИ

Заголовок: «Постановка задачи»

Текст на слайде:

Цель: разработать программу для автоматического определения эмоциональной окраски текста на русском языке.

Принцип работы:

1. Пользователь вводит текст на русском языке
2. Программа выполняет предобработку и классификацию
3. Выводит метку эмоции и уверенность (%)

Пример:

Ввод: «Меня это бесит, я в ярости!»

Вывод: Эмоция: гнев, Уверенность: 92%

Подсказка: Говори: «Задача — классификация текста по эмоциям. 10 классов эмоций, multi-label разметка.»

СЛАЙД 3: ОБЛАСТЬ ПРИМЕНЕНИЯ

Заголовок: «Область применения»

Текст:

- Анализ тональности в соцсетях и системах обратной связи
- Поддержка чат-ботов и систем мониторинга тональности
- Учебно-исследовательские цели (курсовые и дипломы по NLP)

СЛАЙД 4: ДАТАСЕТ

Заголовок: «Датасет: ru-izard-emotions»

Текст:

- Источник: Hugging Face (автор Djacon)
- ~25 000 текстов на русском языке
- 10 классов эмоций по модели Изарда
- Multi-label: один текст может иметь несколько эмоций
- Разбиение: 80/20, seed=42

Таблица эмоций:

Русский	English
Радость	joy
Грусть	sadness
Гнев	anger
Страх	fear
Удивление	surprise
Отвращение	disgust
Воодушевление	enthusiasm
Вина	guilt
Стыд	shame
Нейтральность	neutral

СЛАЙД 5: ПАЙПЛАЙН ОБРАБОТКИ

Заголовок: «Архитектура: пайплайн обработки текста»

Вставь сюда схему из раздела 4 этого документа (стр. 4) — блок-схема с двумя ветками (TF-IDF и BERT).

Или упрощённая версия — 5 блоков со стрелками:

[Текст] → [Предобработка] → [Векторизация] → [Классификация] → [Эмоция + %]

Подсказка: Это ключевой слайд. Говори: «Текст проходит 4 этапа обработки. Сначала чистим от шума, потом превращаем в числа, подаём на вход модели, получаем результат.»

СЛАЙД 6: ПРЕДОБРАБОТКА ТЕКСТА

Заголовок: «Предобработка текста»

4 этапа:

1. Lowercase — приведение к нижнему регистру
2. Удаление знаков препинания и спецсимволов
3. Удаление стоп-слов (NLTK, русский язык)
4. Лемматизация (pymorphy2) — «бесит» → «бесить»

Пример трансформации:

«Меня это бесит, я в ярости!»

→ lowercase → без пунктуации → без стоп-слов

→ лемматизация → «бесить ярость»

Подсказка: «Предобработка убирает шум. Модели проще работать с леммами.»

СЛАЙД 7: МОДЕЛИ КЛАССИФИКАЦИИ

Заголовок: «Модели классификации»

Два блока:

Baseline (простая модель):

- TF-IDF → LogisticRegression (OneVsRest)
- Быстро обучается, но невысокая точность

Основная (нейросеть):

- BERT (rubert-tiny2) — трансформер для русского языка
- Fine-tuning на наших данных
- Понимает контекст → лучше по метрикам

Подсказка: «BERT учитывает порядок и контекст слов, а TF-IDF — нет.»

СЛАЙД 8: РЕЗУЛЬТАТЫ

Заголовок: «Результаты: сравнение моделей»

Таблица:

Метрика	TF-IDF+LogReg	BERT
F1-score (macro)	0.29	0.49
Top-1 Accuracy	44.6%	47.1%
Recall (macro)	0.20	0.43

Вставь картинку: models/confusion_matrix_bert_single.png

Вывод: BERT лучше baseline по всем метрикам.

Подсказка: «F1 у BERT 0.49 против 0.29 — почти вдвое лучше. Confusion Matrix показывает, какие эмоции путаются.»

СЛАЙД 9: ДЕМОНСТРАЦИЯ

Заголовок: «Демонстрация работы»

Вставь скриншот консоли (python3 main.py --bert).

Введите текст: Меня это бесит, я в ярости!
Эмоция: гнев
Уверенность: 92%

Введите текст: Какой прекрасный день!
Эмоция: радость
Уверенность: 78%

Подсказка: Если можно — сделай живую демо на защите.

СЛАЙД 10: СТЕК ТЕХНОЛОГИЙ

Заголовок: «Стек технологий»

Таблица из 3 колонок:

Назначение	Технология	Зачем
Язык	Python 3.8+	Основной язык
NLP	NLTK	Стоп-слова русского языка
NLP	py morphology2	Лемматизация
NLP	re (regex)	Удаление пунктуации
Векторизация	scikit-learn	TF-IDF: текст -> вектор
Векторизация	Transformers	BERT-эмбединги (rubert-tiny2)
ML-модели	scikit-learn	LogReg, RandomForest, метрики
Нейросеть	PyTorch	Обучение BERT
Данные	pandas	Таблицы данных
Данные	HF Datasets	Загрузка датасета
Графики	matplotlib	Confusion Matrix
Сохранение	joblib/torch	Модели (.pkl, .pt)

Подсказка: «Не просто набор библиотек — каждая решает конкретную задачу в пайплайне.»

СЛАЙД 11: ВЫВОДЫ

Заголовок: «Выводы»

Текст (4 пункта):

1. Разработана программа классификации эмоций на русском языке
2. Реализованы два подхода: TF-IDF+LogReg и BERT (rubert-tiny2)
3. BERT: F1=0.49, вдвое лучше baseline (0.29)
4. Все требования ТЗ выполнены

Подсказка: «Трансформеры превосходят классику на задаче эмоций. Программа соответствует ТЗ и готова к эксплуатации.»

7. Какие диаграммы вставить в отчёт

В отчёт (пояснительную записку) нужно вставить:

1. Use Case диаграмма (стр. 2) — раздел «Функциональное назначение»
2. Class Diagram (стр. 3) — раздел «Архитектура программы»
3. Object Diagram (стр. 4) — раздел «Пример работы программы»
4. Схема пайплайна (стр. 5) — раздел «Алгоритм обработки»
5. Архитектура файлов (стр. 5) — раздел «Структура проекта»
6. Confusion Matrix (файл models/confusion_matrix_bert_single.png) — раздел «Результаты»

Все диаграммы из этого документа можно использовать как есть — сделай скриншот нужной страницы и вставь в отчёт или презентацию.